

İstanbul Topkapi Üniversitesi

FET302 -Derin Öğrenme 2025-2026 Güz Dönemi

Proje Konusu

CNN Tabanlı Türk İşaret Dili Tanıma

DeepSign

Ekip Üyeleri

- Emrullah Yıldız - 23040301101 - emrullahyildiz1@stu.topkapi.edu.tr
- Ali Zeynel Sönmez - 23040301053 - alizeynelsonmez@stu.topkapi.edu.tr
 - Berkay Aras - 23040301055 - berkayaras@stu.topkapi.edu.tr
 - Hüseyin Kaba - 23040301086 - huseyinkaba@stu.topkapi.edu.tr



<https://youtu.be/sdvqIHrtHyk>

Problem ve Motivasyon

PROBLEM TANIMI

- Türk İşaret Dili, işitme engelli bireylerin iletişiminde temel bir rol oynamaktadır. Toplumun büyük kısmı işaret dili bilmediği için iletişim çoğu zaman sınırlı kalmaktadır.
- Problem, görüntü tabanlı çok sınıflı sınıflandırma problemi olarak ele alınmıştır.

Amaç ve Motivasyon

- Bu çalışmanın amacı, Türk İşaret Dili alfabesinde ait el hareketlerini görüntüler üzerinde doğru ve güvenilir şekilde sınıflandırabilen bir derin öğrenme yaklaşımı geliştirmektir. Geliştirilen bu modellerden en başarılı olanı çeşitli metrikler üzerinden test etmek amaçlanmıştır.




Veri Seti ve Başarı Kriterleri

- Projede kullanılacak temel veri kümesi TR Sign Language Dataset (Kaggle)'tir. Görüntüler, farklı ışıklandırma ve arka plan koşullarında çekildiği için, eğitilen modelin genelleme yeteneğini test etmek için gerçekçi bir zemin sunmaktadır.
- Veri seti, 29 sınıf (harf) içermektedir ve her sınıfta yaklaşık 4800 görsel bulunmaktadır. Toplamda yaklaşık 167.186 görüntü (data point) içerir. Görsellerin boyutu 200×200 RGB piksel şeklindedir.
- Veri setindeki görseller 128*128 boyutunda yeniden ölçeklendirilmiştir.
- Veri bölünmesi %80 train , %10 validation, %10 test olacak şekilde gerçekleştirilmiştir.
- Nicel Hedefler → Accuracy ≥ 0.85 -- F1 Score ≥ 0.80
- Temel Metrikler: Accuracy, Precision, Recall, F1-Score
- 🗣 Veri Seti Linki:
<https://www.kaggle.com/datasets/berkaykocaoglu/tr-sign-language>



İlk Aşama: Base Modeller


- Projenin ilk fazında, problemi anlamak ve bir temel performans çizgisi belirlemek amacıyla dört farklı mimari geliştirildi. Her ekip üyesi, belirli bir modeli ve o modelin kritik bir hiperparametresini optimize etmekle görevlendirildi.
- Yapılan hiperparametre optimizasyon deneyleri sonucunda, dört modelden üçü belirlenen hedefleri başarıyla aşmış ve en yüksek sonucu Custom CNN modelimiz vermiştir.

Ekip Üyesi	Model	Optimize Edilen Hiperparametre
Berkay Aras	LeNet-5 	Dropout Oranı (0.0, 0.25, 0.50) 
Emrullah Yıldız	Custom CNN (3 katmanlı) 	Batch Size (32, 64, 128) 
Hüseyin Kaba	AlexNet 	Öğrenme Oranı (0.001, 0.0005, 0.0001) 
Ali Z. Sönmez	Custom CNN (Farklı tasarım) 	Optimizer (Adam vs. SGD) ve Batch Size 

Grup Üyesi	Uygulanan Base Model	Optimize Edilmiş Değer	Accuracy	F1-Score
Emrullah Yıldız	Custom CNN	Batch size: 64	0.950	0.950
Hüseyin Kaba	AlexNet	LR: 0.0001	0.933	0.933
Berkay Aras	LeNet-5	Dropout: 0.0	0.873	0.879
Ali Z. Sönmez	Custom CNN	Batch size: 64	0.800	0.810

İkinci Aşama: Gelişmiş Modeller

- İkinci aşamada ise 8 adet güçlü ve gelişmiş model TİD tanıma görevi için uyarlanmış ve ortak karşılaştırma çerçevesinde karşılaştırılmıştır.
- Tüm gelişmiş modeller , ImageNet üzerinde önceden eğitilmiş ağırlıklarla başlatıldı. Bu, modelin temel görsel özellikleri sıfırdan öğrenmesi yerine, mevcut bilgisini TİD' e özel el şekillerini öğrenmek için kullanmasını sağlar.



Gelişmiş Modeller

DenseNet121 – ResNet18 – ResNet50 – VGG16

DenseNet121

- ❖ En iyi hiperparametre değerleri: LR: 0.0005 | Batch: 64 | Optimizer: Adam bulunup bu değerler ile train yapılmıştır.
- ❖ İlk olarak freeze uygulanıp 10 epoch ardından tüm katmanlar açılarak 5 epoch'luk fine tune uygulanıp modelin performansı arttırılmıştır. Model, %99.89 gibi yüksek bir performans vermiştir.

Resnet18

- ❖ Skip-Connection yapısı ile derin ağlardaki gradyan kaybı azaltılmıştır.
- ❖ LR: 0.0005 | Batch: 64 | Optimizer: Adam hiperparametre değerleri kullanılarak %99.67'lik bir test accuracy'e ulaşılmıştır.
- ❖ Eğitim aşaması 10 epoch freeze + 5 epoch fine tuning yapılması ile gerçekleşmiştir.

Resnet50

- ❖ Daha derin yapısı sayesinde görüntü özelliklerini daha detaylı çıkarmaktadır.
- ❖ LR: 0.0005 | Batch: 64 | Optimizer: Adam parametreleri kullanılarak 10 + 5 epoch olacak şekilde eğitilmiştir.
- ❖ Resnet18'e çok yakın sonuç vermesine rağmen daha ağır model olduğu için hesaplama maliyeti yüksektir.

VGG16

- ❖ Derin bir mimari olmasına rağmen diğer modellere göre daha yavaştır.
- ❖ LR: 0.0003 – Batch 128 – Adam kullanılmış ve %99.39'luk bir test accuracy başarısı göstermiştir.

Gelişmiş Modeller

MobileNetV2 – ShuffleNetV2 – EfficientNetB0 – InceptionV3

MobileNetV2

- ❖ Bu modelde gövde dondurulmuş ve sadece son sınıflandırıcı katman eğitilmiştir. Fine tuning uygulanmamıştır.
- ❖ En iyi konfigürasyon LR: 0.0005 | Batch 64 | Adam olup test accuracy %99.89 gibi çok yüksek bir sonuç çıkmıştır.
- ❖ Gerçek zamanlı tanıma için en uygun modeldir.
- ❖ DenseNet121 ile birlikte en yüksek başarıyı vermiştir.

ShuffleNetV2

- ❖ Performansı yüksek ve inference süresi çok hızlıdır. Model kanal bölme yöntemi ile hızlı çalışmaktadır.
- ❖ LR: 0.0005 | Batch 64 | Adam parametreleri ile eğitilmiş ve %99.82 gibi yüksek bir sonuç vermiştir.

EfficientNetB0

- ❖ İyi bir sonuç vermesine rağmen diğer üst modellerden geride kalmıştır.
- ❖ LR: 0.001 – Batch 64 – Adam parametreleri kullanılarak eğitilen model %96.96 gibi yüksek bir accuracy sonucu vermiştir.

InceptionV3

- ❖ Çoklu kernel yapıları ile feature extraction çeşitliliği sağlamaktadır.
- ❖ LR: 0.0005 – Batch 64 – Adam parametreleri ile eğitilen model %77.40 gibi bir sonuçla diğer modellerden düşük bir sonuç vermiştir.

Klasik ve Residual Mimariler

VGG16 (Referans Model)

Hiperparametre Arama Alanı

- LR: {0.001, 0.0005, 0.0003},
BS: {128}, Optimizer: {Adam,
SGD}

Bulunan En İyi Konfigürasyon

- LR: 0.0003, BS: 128, Optimizer:
Adam

Test Sonucu (Macro F1-Score)

%99.43

ResNet-50 (Derin Residual Ağ)

Hiperparametre Arama Alanı

- LR: {0.001, 0.0005, 0.0003},
BS: {64}, Optimizer: {Adam,
SGD}

Bulunan En İyi Konfigürasyon

- LR: 0.0005, BS: 64, Optimizer:
Adam

Test Sonucu (Macro F1-Score)

~%99.5

ResNet-18 (Hafif Residual Ağ)

Hiperparametre Arama Alanı

- LR: {0.001, 0.0005, 0.0003},
BS: {64}, Optimizer: {Adam,
SGD}

Bulunan En İyi Konfigürasyon

- LR: 0.0005, BS: 64, Optimizer:
Adam

Test Sonucu (Macro F1-Score)

~%99.69

Modern Mimariler

Verimlilik ve Performans Dengesi

DenseNet-121 (Yoğun Bağlantılı Ağ)

Hiperparametre Arama Alanı

LR: {0.001, 0.0005, 0.0003}, BS: {32, 64}, Optimizer: {Adam, SGD}

Bulunan En İyi Konfigürasyon

LR: 0.0005, BS: 64, Optimizer: Adam

Test Sonucu (Macro F1-Score)

%99.89

EfficientNet-B0 (Bileşik Ölçekleme)

Hiperparametre Arama Alanı

LR: {0.001, 0.0005, 0.0003}, BS: {64, 128}, Optimizer: {Adam, SGD}

Bulunan En İyi Konfigürasyon

LR: 0.001, BS: 64, Optimizer: Adam

Test Sonucu (Macro F1-Score)

%97.13

InceptionV3 (Çok Dallı Yapı)

Hiperparametre Arama Alanı

LR: {0.001, 0.0005}, BS: {64}, Optimizer: {Adam}

Bulunan En İyi Konfigürasyon

LR: 0.0005, BS: 64, Optimizer: Adam

Test Sonucu (Macro F1-Score)

%77.49

(Diğerlerine göre belirgin şekilde düşük)

Mobil Odaklı Mimariler

MobileNetV2

(Ters Çevrilmiş Rezidüel Bloklar)

****Strateji Notu*:** Bu modelde gövde donduruldu, sadece son sınıflandırıcı katman eğitildi. Fine-tuning yapılmadı.

Hiperparametre Arama Alanı

- LR: {0.001, 0.0005, 0.0003}, BS: {64}, Optimizer: {Adam, SGD}

Bulunan En İyi Konfigürasyon

LR: 0.0005, BS: 64, Optimizer: SGD

Test Sonucu (Macro F1-Score)

%99.89

ShuffleNetV2

(Kanal Karıştırma ve Grup Evrişim)

****Strateji Notu:** MobileNetV2'ye benzer şekilde, gövde ağırlıkları dondurularak sadece son katman eğitildi.

Hiperparametre Arama Alanı

- LR: {0.001, 0.0005, 0.0003}, BS: {64}, Optimizer: {Adam, SGD}

Bulunan En İyi Konfigürasyon

LR: 0.0005, BS: 64, Optimizer: Adam

Test Sonucu (Macro F1-Score)

~%99.8

Modellerin Genel Karşılaştırılması

- MobileNetV2 ve DenseNet121 en yüksek başarıyı elde etmiş ve %99,89 seviyesinde F1 skoruna ulaşmıştır. Ardından yüksek bir skorla ShuffleNet modeli gelmektedir.
- InceptionV3 veri setine uyum sağlamakta zorlanmış ve açık ara farkla en düşük sonucu üretmiştir.
- Resnet-18, hem yüksek performansları hem de görece daha hafif yapılarıyla dikkat çekmektedir. Özellikle daha derin olan Resnet-50'yi geçmesi önemlidir.

GENEL KARŞILAŞTIRMA TABLOSU

	Model	Accuracy	Precision	Recall	F1
0	DenseNet121	0.9988	0.9989	0.9989	0.9989
1	EfficientNetB0	0.9697	0.9716	0.9714	0.9713
2	MobileNetV2	0.9988	0.9989	0.9989	0.9989
3	ResNet18	0.9967	0.9969	0.9969	0.9969
4	ResNet50	0.9955	0.9952	0.9952	0.9952
5	ShuffleNetV2	0.9981	0.9982	0.9982	0.9982
6	VGG16	0.9939	0.9943	0.9942	0.9942
7	InceptionV3	0.7612	0.7939	0.7746	0.7749
8	AlexNet	0.9327	0.9354	0.9327	0.9330
9	LeNet5	0.8727	0.8223	0.8922	0.8794
10	CustomCNN1	0.9532	0.9359	0.9487	0.9499
11	CustomCNN2	0.8232	0.8123	0.8245	0.8145

Zirvedeki Üçlü: Neredeyse Kusursuz Sonuçlar

DenseNet121

%99.89

Özellik: Derin bağlantı yapısıyla özellik haritalarını verimli kullanır.



MobileNetV2

%99.89


Özellik: Düşük hesaplama maliyetiyle mobil cihazlar için optimize edilmiştir.



ShuffleNetV2

%99.82

Özellik: Hafif yapısı ve hızıyla öne çıkar.



Anahtar Bulgu: En şaşırtıcı sonuçlardan biri, mobil cihazlar için tasarlanmış hafif bir model olan **MobileNetV2'nin**, çok daha karmaşık ve derin olan **DenseNet121** ile birebir aynı performansı göstermesidir. Bu, yüksek doğruluk için her zaman devasa modellere ihtiyaç olmadığını kanıtlıyor.

Sınıf Bazlı Karşılaştırma

- ❖ Sınıf bazında F1 skorları incelendiğinde, genel tablodaki F1 skorları pekişmektedir.
- ❖ DenseNet121, EfficientNetB0, MobileNetV2 ve ShuffleNetV2 modellerin 26 sınıfın 21 tanesinde liderliği paylaşmışlardır.
- ❖ ResNet18 modeli birçok sınıfta liderliğe yaklaşıp da, en üst 4 model kadar baskın bir profil sergilememiştir.
- ❖ InceptionV3 ve ilk aşamada geliştirilen temel modeller sınıfları ayırmada düşük performans göstermiştir. Görsel olarak karmaşık işaretlerde başarısız olmuşlardır.

	Class	Best Model(s)	Best F1
0	A	ResNet18	99.85
1	B	DenseNet121, EfficientNetB0, MobileNetV2, ResN...	99.97
2	C	DenseNet121, EfficientNetB0, MobileNetV2, Shuf...	99.92
3	D	DenseNet121, EfficientNetB0, MobileNetV2, Shuf...	99.85
4	E	ResNet18	99.97
5	F	DenseNet121, EfficientNetB0, MobileNetV2, Shuf...	99.95
6	G	DenseNet121, EfficientNetB0, MobileNetV2, Shuf...	99.95
7	H	ResNet18	99.97
8	I	DenseNet121, EfficientNetB0, MobileNetV2, Shuf...	99.92
9	J	DenseNet121, EfficientNetB0, MobileNetV2, Shuf...	99.90
10	K	DenseNet121, EfficientNetB0, MobileNetV2, ResN...	100.00
11	L	DenseNet121, EfficientNetB0, MobileNetV2, Shuf...	99.90
12	M	DenseNet121, EfficientNetB0, MobileNetV2, Shuf...	99.36
13	N	DenseNet121, EfficientNetB0, MobileNetV2, Shuf...	99.30
14	O	DenseNet121, EfficientNetB0, MobileNetV2, Shuf...	99.97
15	P	ResNet18	99.92
16	R	DenseNet121, EfficientNetB0, MobileNetV2, Shuf...	99.79
17	S	DenseNet121, EfficientNetB0, MobileNetV2, Shuf...	99.95
18	T	DenseNet121, EfficientNetB0, MobileNetV2, Shuf...	99.95
19	U	DenseNet121, EfficientNetB0, MobileNetV2, ResN...	99.97
20	V	DenseNet121, EfficientNetB0, MobileNetV2, Shuf...	99.97
21	Y	DenseNet121, EfficientNetB0, MobileNetV2, Shuf...	100.00
22	Z	ResNet18	99.95
23	del	DenseNet121, EfficientNetB0, MobileNetV2, ResN...	100.00
24	nothing	DenseNet121, EfficientNetB0, MobileNetV2, ResN...	100.00
25	space	DenseNet121, EfficientNetB0, MobileNetV2, ResN...	100.00

Sınıf Bazlı Karşılaştırma

	Class	DenseNet121	EfficientNetB0	MobileNetV2	ResNet18	ResNet50	ShuffleNetV2	VGG16	InceptionV3	AlexNet	LeNet5	CustomCNN1	CustomCNN2
0	A	99.795082	99.795082	99.795082	99.846154	99.539877	99.795082	99.743458	70.345500	94.000000	85.000000	94.000000	79.000000
1	B	99.974073	99.974073	99.974073	99.948160	99.974073	99.974073	99.321503	92.000000	97.000000	92.000000	98.000000	81.000000
2	C	99.923215	99.923215	99.923215	99.795082	99.846311	99.923215	99.769880	71.000000	95.000000	90.000000	96.000000	82.000000
3	D	99.845917	99.845917	99.845917	98.106539	99.743326	99.845917	98.542426	63.000000	93.000000	81.000000	93.000000	73.000000
4	E	99.948560	99.948560	99.948560	99.974273	99.897172	99.948560	99.614693	77.000000	93.000000	89.000000	96.000000	84.000000
5	F	99.949341	99.949341	99.949341	99.873257	99.898734	99.949341	99.696203	81.000000	94.000000	89.000000	96.000000	83.000000
6	G	99.948613	99.948613	99.948613	99.845996	99.845758	99.948613	98.778626	71.000000	93.000000	86.000000	94.000000	75.000000
7	H	99.923136	99.923136	99.923136	99.974379	99.614693	99.923136	99.820559	69.000000	95.000000	88.000000	94.000000	77.000000
8	I	99.922420	99.922420	99.922420	99.741736	99.844640	99.922420	99.612703	75.000000	93.000000	89.000000	96.000000	77.000000
9	J	99.897066	99.897066	99.897066	99.640103	99.536560	99.897066	99.146625	65.000000	88.000000	84.000000	95.000000	74.000000
10	K	100.000000	100.000000	100.000000	100.000000	99.897331	100.000000	99.514935	81.000000	95.000000	90.000000	96.000000	84.000000
11	L	99.897907	99.897907	99.897907	99.642492	99.795918	99.897907	99.338422	69.000000	92.000000	81.000000	94.000000	70.000000
12	M	99.355172	99.355172	99.355172	99.201648	98.183679	99.355172	98.011219	67.000000	89.000000	77.000000	84.000000	74.000000
13	N	99.302506	99.302506	99.302506	99.172271	98.022893	99.302506	97.856769	70.000000	88.000000	79.000000	87.000000	64.000000
14	O	99.974300	99.974300	99.974300	99.948613	99.922899	99.974300	99.251226	74.000000	94.000000	86.000000	96.000000	80.000000
15	P	99.872155	99.872155	99.872155	99.923254	99.923215	99.872155	99.821018	84.000000	96.000000	91.000000	96.000000	88.000000
16	R	99.793388	99.793388	99.793388	99.741869	99.767382	99.793388	99.559928	70.000000	95.000000	86.000000	96.000000	81.000000
17	S	99.948849	99.948849	99.948849	99.743852	98.836307	99.948849	99.288618	80.000000	93.000000	88.000000	94.000000	79.000000
18	T	99.948901	99.948901	99.948901	98.261997	98.614261	99.948901	99.564884	69.000000	91.000000	87.000000	96.000000	74.000000
19	U	99.974033	99.974033	99.974033	99.896212	99.974033	99.974033	99.688474	80.000000	96.000000	91.000000	98.000000	85.000000
20	V	99.974313	99.974313	99.974313	99.716714	99.922939	99.974313	99.845838	76.000000	90.000000	83.000000	95.000000	77.000000
21	Y	100.000000	100.000000	100.000000	99.948797	99.948797	100.000000	99.846469	81.000000	94.000000	86.000000	97.000000	85.000000
22	Z	99.948875	99.948875	99.948875	99.948901	99.948875	99.948875	99.390554	77.000000	89.000000	90.000000	96.000000	82.000000
23	del	100.000000	100.000000	100.000000	100.000000	98.425597	100.000000	100.000000	100.000000	100.000000	100.000000	100.000000	100.000000
24	nothing	100.000000	100.000000	100.000000	100.000000	100.000000	100.000000	100.000000	100.000000	100.000000	100.000000	100.000000	100.000000
25	space	100.000000	100.000000	100.000000	100.000000	98.473658	100.000000	100.000000	100.000000	100.000000	100.000000	100.000000	100.000000

Şampiyonların Profili & Projenin Ana Çıkarımları

Kazanan Mimariler

🏆 **DenseNet121:** %99.88 Accuracy.

Derin ve yoğun bağlantılı yapısı, özellik haritalarını etkin bir şekilde kullanarak TİD veri setinde üstün bir performans sergilemiştir.

🏆 **MobileNetV2:** %99.88 Accuracy.

Hafif yapısına ve sadece son katmanının eğitilmesine rağmen, DenseNet ile aynı zirve performansına ulaşarak verimliliğin ve doğruluğun bir arada olabileceğini kanıtlamıştır.

Önemli Stratejik Bulgular



Hafif Modellerin Gücü: MobileNetV2 ve ShuffleNetV2 gibi mobil-optimize modeller, en yüksek doğruluk seviyelerine ulaşarak bu görev için son derece verimli çözümler sunmuştur.



Derinliğin Avantajı: DenseNet ve ResNet gibi derin bağlantı yapılarına sahip modellerin, TİD el işaretlerindeki karmaşık örüntüleri öğrenmede basit CNN'lere göre ezici bir üstünlüğü vardır.



Mimari Uyumu Kritik: InceptionV3 ve EfficientNet-B0'ın göreceli olarak düşük performansı, her modern mimarinin her veri setine aynı derecede iyi uyum sağlamadığını göstermektedir.

Bu görev özelindeki çıkarım sonucu, modern, verimlilik odaklı ve derin bağlantı yapılarına sahip mimariler; hem klasik derin ağlardan hem de özel tasarlanmış sığ ağlardan kesin bir şekilde daha üstündür.

Sonuç: Bu Yolculuk Bize Ne Öğretti?

1



Transfer Learning'in Ezici Gücü

Ön-eğitilmiş modeller, TİD gibi niş ve özel bir veri setinde bile sıfırdan eğitilen modellere kıyasla çok daha üstün sonuçlar vermektedir.

2



Verimlilik Kralıdır

MobileNetV2 ve ShuffleNetV2 gibi 'hafif' modeller, en karmaşık mimarilerle başa baş performans sergileyerek, yüksek doğruluk için her zaman en büyük modellere ihtiyaç olmadığını kanıtlamıştır.

3



Her Mimari Her Probleme Uygun Değildir

InceptionV3'ün göreceli olarak düşük performansı, model seçimi ile veri setinin yapısı arasındaki uyumun kritik önemini göstermektedir.

4



Sistemik Deney Şarttır

Hem temel hem de gelişmiş modeller üzerinde uygulanan hiperparametre optimizasyonu ve adil karşılaştırma çerçevesi, güvenilir ve anlamlı sonuçlar elde etmenin temelidir.

DeepSign'ın Anlamı ve Gelecek Adımlar

Neden Heyecan Verici?

Bu çalışma, **TİD için %99.8'in üzerinde doğrulukla çalışan**, gerçek zamanlı uygulamalara temel oluşturabilecek modelleri tanımlamıştır. Özellikle MobileNetV2'nin başarısı, bu teknolojinin **mobil cihazlarda dahi verimli bir şekilde çalışabileceğinin** somut bir kanıtıdır.



Literatüre Katkımız

TİD üzerinde bu kadar **geniş bir mimari yelpazesini** (basit, klasik, mobil, residual) sistematik olarak karşılaştıran sınırlı sayıda çalışmalardan birini gerçekleştirdik.



Gelecek Adımlar

- En başarılı modelleri gerçek zamanlı video akışlarında test etmek.
- Alfabe tanımadan kelime ve cümle tanımaya yönelmek.
- Modeli mobil bir uygulamaya entegre etmek.



Bilimsel Temeller ve Referanslar

Huang, G. et al. (2017). 'Densely Connected Convolutional Networks.' (DenseNet)

He, K. et al. (2016). 'Deep Residual Learning for Image Recognition.' (ResNet)

Sandler, M. et al. (2018). 'MobileNetV2: Inverted Residuals and Linear Bottlenecks.'

Ma, N. et al. (2018). 'ShuffleNet V2: Practical Guidelines for Efficient CNN Architecture Design.'

Tan, M. & Le, Q. V. (2019). 'EfficientNet: Rethinking Model Scaling for CNNs.'

Krizhevsky, A. et al. (2012). 'ImageNet Classification with Deep Convolutional Neural Networks.' (AlexNet)

LeCun, Y. et al. (1998). 'Gradient-based learning applied to document recognition.' (LeNet)

Kaggle (2023). 'TR Sign Language Dataset.'

[<https://www.kaggle.com/datasets/berkaykocaoglu/tr-sign-language>]

Projeyi Keşfedin

Emrullah Yıldız • Hüseyin Kaba • Ali Zeynel Sönmez • Berkay Aras

Bu çalışmada kullanılan tüm kodlara, modellere ve deney detaylarına aşağıdaki GitHub reposundan ulaşabilirsiniz.



<https://github.com/Byte52/DeepSign-Proje>